

基于 SkLearn 的短视频平台机器学习推荐模型报告

一、 数据来源

本数据集主要来自于“快手短视频”2022 年 4 月~5 月两个月期间的视频数据、用户数据、平台日志等。本研究的数维度主要包含视频 id、作者 id、视频类型、上传方式、上传时间、视频持续时间、音乐 id、分辨率、标签等，数据量超过 7000。此外还使用了视频统计数据集，主要是视频完播率、点赞数等。

数据预处理主要包括去除空值（NULL），以及修改数据类型等。其中，视频类型为广告的数据在 music_id 和 muic_type 栏皆为空值，可能是因为没有统计或者视频类型为照片造成的，所以在预处理中全部改为了 0，方便后续进行研究和计算。

二、 使用模型

本推荐模型主要基于两个小机器学习模型，分别是分类模型 KNN 和聚类模型 k-mean。分类模型主要对视频的质量进行打分，将视频区分成为 1 级、2 级、3 级等不同等级，评估视频质量。KNN 是一种监督学习算法，适用于分类和回归任务，其核心思想是“物以类聚”，即通过计算待预测样本与训练集中所有样本的距离，选取最近的 k 个样本，再通过投票（分类）或取平均值（回归）确定结果。它的优势在于简单易懂、无需训练过程且对异常值不敏感，常见于手写数字识别、推荐系统等场景。




图 1 推荐模型流程图

而聚类模型主要针对用户，将具有相似特征的用户聚为一类，统计这类人群的视频倾向（标签），从而在他们所属的群中推荐共同的视频标签。K-Means 核心是将数据集划分为 k 个簇，使簇内样本相似度高、簇间相似度低。其过程为随机选择 k 个初始聚类中心，计算样本与中心的距离并分配

到对应簇，再重新计算簇中心，重复此过程直至中心稳定。该算法原理简单、收敛快，适用于大规模数据集，可用于客户分群、图像分割等。

在将用户进行不同分群，并获得视频标签后，再通过标签（tag）查询对应视频，从而获得该标签下的所有视频 id。随后利用打分系统对视频进行评价，确保推荐的视频是高质量视频。再获得一定程度的高质量视频后，查询用户的访问记录，将未观看过的视频推送给用户，完成一套推荐流程。

三、 模型搭建

1. K-mean 模型

1) 输入数据模块：

输入主要包括从 SQL 库调取文件、数据预处理、创建聚类特征三个部分。

本数据集主要包括一下数据维度，由 SQL 数据库中关联查询得出。

#	Column	Non-Null	Count	Dtype
0	user_id	5000 non-null		int64
1	video_id	5000 non-null		int64
2	play_time_ms	5000 non-null		int64
3	video_type	4994 non-null		float64
4	music_type	5000 non-null		float64
5	user_active_degree	0 non-null		float64
6	is_live_streamer	5000 non-null		int64
7	is_video_author	5000 non-null		int64
8	follow_user_num	5000 non-null		int64
9	fans_user_num	5000 non-null		int64
10	friends_user_num	5000 non-null		int64
11	tag1	5000 non-null		int64
12	tag2	5000 non-null		int64
13	tag3	5000 non-null		int64
14	user_active_code	5000 non-null		int64

dtypes: float64(3), int64(12)
memory usage: 586.1 KB

表 1 数据类型和数据形式

数据预处理部分将视频标签进行分离，将字符型数据进行编码，编码对应如下：

```
Video_type:      Normal == 1
Video_type:      AD == 0
User_active_degree: 'full_active' == 0
                  '2_14_day_new' == 1
                  'high_active' == 2
                  'middle_active' == 3
                  'low_active' == 4
```

本研究构建了涵盖四个维度的特征体系：播放行为体系、用户属性特征、内容偏好特征、标签偏好特征。

播放行为特征包括基于 play_time_ms 的平均播放时长、总播放时长及基于 video_id 去重计数的观看视频数量；用户属性特征选取是否为直播主播、是否为视频创作者、关注用户数、粉丝数、好友数及用户活跃标识，均取分组内首个观测值；内容偏好特征包含基于 video_type 均值的视频类型偏好及基于 music_type 众数（无众数时取 0）的主导音乐类型；标签偏好特征则通过非零值占比计算三个核心标签的出现频率。所有特征均基于分组数据计算并重置索引，为后续建模提供标准化输入。

2) 模型构建

首先从用户特征数据中提取排除 `user_id` 后的特征列，将其转换为数值矩阵；随后使用 `StandardScaler` 进行特征标准化（因聚类算法对特征尺度敏感）；接着应用 `K-Means` 算法（设置聚类数为 `n_clusters`，随机种子 42）执行聚类，为每个用户分配聚类标签；最终返回含聚类结果的用户特征数据及所用的标准化器和聚类模型。

```
def cluster_users(user_features, n_clusters=5):
    """对用户进行聚类"""
    # 提取特征列（排除user_id）
    feature_cols = user_features.columns.drop('user_id')
    X = user_features[feature_cols].values

    # 特征标准化（聚类算法对尺度敏感）
    scaler = StandardScaler()
    X_scaled = scaler.fit_transform(X)

    # 应用K-Means聚类
    kmeans = KMeans(n_clusters=n_clusters, random_state=42)
    user_features['cluster'] = kmeans.fit_predict(X_scaled)

    return user_features, scaler, kmeans
```

图 2 模型构建代码

3) 推荐程序

标签推荐函数通过以下步骤为目标用户生成推荐标签：首先确定目标用户所属聚类；其次筛选出该聚类中的所有用户；然后收集这些用户观看内容的所有非零标签（涵盖 `tag1`、`tag2`、`tag3`）；最后统计标签出现频率并按降序排序，返回前 `N` 个高频标签作为推荐结果。

4) 推荐结果展示

请输入用户 id: 10030

```
=====
【步骤 1】加载数据中...
=====
【步骤 2】创建用户特征...
=====
【步骤 3】聚类用户中...
=====
【步骤 4】推荐结果
```

为用户 10030 推荐的标签：

1. 39.0
2. 12.0
3. 6.0
4. 9.0
5. 68.0

2. KNN 模型

- 1) 输入数据模块
基本同上。
- 2) 数据统计描述与热力图




图 3 数据统计描述




图 4 数据维度热力图

3) 模型构建

首先加载数据处理模块并获取预处理数据集；通过特征工程阶段，将数据集划分为特征空间 X（剔除 video_id、quality_level 及 play_progress 字段）与目标变量 y（quality_level）；采用分层抽样策略按 8:2 比例拆分训练集与测试集，设置 random_state=42 以保证实验可复现性。考虑到 KNN 算法对特征尺度的敏感性，使用 StandardScaler 进行特征标准化，严格遵循“训练集拟合 - 双集转换”的规范流程；构建 k=3 的 K 近邻分类器并在标准化训练集上完成参数学习。

最后使用 joblib 包，序列化保存模型参数、标准化器及特征列名至指定路径，其中特征列名的持久化存储为后续预测阶段的特征对齐提供了保障。

```
def load_model_and_scaler():
    """加载保存的模型、标准化器和特征列名"""
    # 加载模型和标准化器
    knn = joblib.load(r'src\sklearn_study\KNN\models\knn_model.pkl')
    scaler = joblib.load(r'src\sklearn_study\KNN\models\scaler.pkl')
    # 加载特征列名
    with open(r'src\sklearn_study\KNN\models\feature_columns.txt', 'r') as f:
        feature_columns = f.read().split(',')
    return knn, scaler, feature_columns

def predict_new_video(new_video_data):
    """预测新视频的质量等级"""
    # 加载模型组件
    knn, scaler, feature_columns = load_model_and_scaler()

    # 确保新视频数据的特征列与训练数据一致
    new_video = pd.DataFrame(new_video_data).reindex(columns=feature_columns, fill_value=0)

    # 标准化新数据
    new_video_scaled = scaler.transform(new_video)

    # 预测
    predicted_level = knn.predict(new_video_scaled)
    return predicted_level[0]
```

图 5 模型加载和预测部分

4) 模型测评结果与评估

模型测评结果和评估如下：

	precision	recall	f1-score	support
1	0.78	0.78	0.78	80
2	0.93	0.95	0.94	1049
3	0.87	0.82	0.85	352
4	0.81	0.72	0.76	36
accuracy			0.91	1517
Macro avg	0.85	0.82	0.83	1517
Weighted avg	0.91	0.91	0.91	1517

精确率指预测为某类的样本中实际属该类的比例，召回率指实际为某类的样本中被正确预测的比例，F1-score 为两者的调和平均，support 为该类实际样本数。模型整体准确率达 91%，表现较好，加权平均指标亦为 91%，说明在占比高的类别上表现稳定；各等级中，2 级视频（样本量最大，

1049 个) 表现最佳 (F1-score 94%)，3 级视频 (352 个样本) 表现良好 (F1-score 85%)，而 1 级 (80 个样本) 和 4 级 (36 个样本) 表现较弱，F1-score 分别为 78%、76%，尤其 4 级因样本最少，召回率仅 72%。改进方向包括解决数据不平衡问题 (如增加 4 级样本或过采样)、补充区分度特征、优化低质量相关特征维度、调整 KNN 参数或尝试其他模型 (如随机森林)，以提升小众类别的识别效果。

3. KNN 和 K-mean 结合使用的预测模型

1) 模型主要流程

模型第一步初始化与用户兴趣建模，以用户 ID 为输入，通过 K-mean 模型的 lunch_recommendation 模块生成用户兴趣标签列表 (tag_list)，构建用户兴趣画像，作为后续内容匹配的核心依据。然后基于兴趣标签，视频候选集生成与数据预处理，通过 find_videos 组件从数据库提取关联视频的多维度特征 (基础属性：分辨率、时长；交互特征：点赞、完播、分享、评论数；标签特征)，并执行标准化处理 (分辨率格式统一、时长单位转换、标签列拆分与格式化)，形成结构化候选视频池。同时通过 SQL 查询用户历史观看记录，构建去重过滤规则。

随后，调用 load_model_and_scaler 加载预训练的 KNN 质量等级预测模型、特征标准化器及特征列名映射表，确保推理环境一致性。通过 predict_new_video 组件对候选视频执行特征对齐、标准化处理及质量等级预测 (1-4 级)，形成视频质量量化指标。

最后推荐决策与结果输出，采用分层推荐策略：优先筛选质量等级 > 3 且未观看的视频；若不满足则选取该标签下质量评分最高的未观看视频。最终按兴趣标签维度组织推荐结果，输出每个标签对应的最优视频 ID，实现兼具用户兴趣匹配与质量保障的个性化推荐。

模型输出展示：

请输入用户 id: 10030

=====

【步骤 1】加载数据中...

=====

【步骤 2】创建用户特征...

=====

【步骤 3】聚类用户中...

=====

【步骤 4】推荐结果

为用户 10030 推荐的标签：

1. 39.0
2. 12.0
3. 6.0
4. 9.0
5. 68.0

=====

加载视频数据库中...

正在根据视频数据库和视频质量为用户推荐优质视频...

推荐用户 10030 的视频为：

类别 39 推荐视频 ID: 453

类别 12 推荐视频 ID: 38

类别 6 推荐视频 ID: 6241
类别 9 推荐视频 ID: 140
类别 68 推荐视频 ID: 1595

2) 具象化展示模块

一个简易的输入和展示模块，包括展示框、思考进度条、思考状态等。



图 6 具象化模块展示

四、 结论

本研究构建了基于 K-Means 聚类模型与 KNN 分类模型的视频个性化推荐系统，整体流程完整且具有实际应用价值。

系统融合了两种经典机器学习模型：K-Means 聚类模型用于用户分群，通过提取用户播放行为、属性、内容偏好及标签偏好四大维度特征，将具有相似特征的用户聚为一类，进而生成反映群体兴趣的标签推荐；KNN 分类模型用于视频质量评估，通过学习视频基础属性（分辨率、时长）与交互特征（点赞、完播等），将视频质量划分为 1-4 级，实现对视频质量的量化分级。

在模型精度方面，KNN 分类模型表现优异，整体准确率达 91%，对样本量较大的 2 级（F1-score 94%）和 3 级视频（F1-score 85%）识别精准，虽对样本量较少的 1 级（F1-score 78%）和 4 级视频（F1-score 76%）存在一定误差，但整体满足质量评估需求；K-Means 聚类模型通过群体兴趣标签的高频统计，能有效捕捉用户偏好，从推荐结果来看，生成的标签与用户历史行为匹配度较高，为后续视频匹配提供了可靠依据。

五、 讨论与总结

该推荐系统融合 K-Means 与 KNN 模型的优势，精度达标、易用性强且适配性良好，具备较高的实际应用价值。

模型的实用性与易用性较高，从用户 ID 输入到兴趣标签生成，再到视频质量筛选与去重推荐，步骤清晰且自动化程度高；同时，K-Means 与 KNN 均为原理简单、部署成本低的算法，无需复杂的算力支持，便于实际场景中的快速应用与维护。模型能较好适应多样化需求：通过用户聚类可覆盖不同兴趣特征的用户群体，实现个性化标签推荐；视频质量分级可适配从低到高的多等级视频评估，兼顾主流质量视频（2 级、3 级）与小众质量视频（1 级、4 级）；此外，系统通过过滤用户已观看视频，避免重复推荐，进一步提升了对实际场景的适配性。

在以后的研究中，可以在算法层面引入 DBSCAN 或谱聚类优化用户分群，采用随机森林、XGBoost 等模型提升视频质量分级精度，尤其改善 1 级、4 级等小众类别的识别效果，同时结合

用户 - 视频嵌入技术捕捉深层兴趣关联；特征层面，增加用户行为时序特征与视频内容语义特征，并建立动态更新机制以响应兴趣变化；推荐策略上，平衡精准性与多样性，引入场景感知与冷启动优化；工程上，搭建实时推荐引擎并完善多维度评估体系。此外，需重点解决当前数据量不足的问题（如 4 级视频样本仅 36 个），通过扩充高质量样本或采用过采样技术，为模型提供更充分的学习基础，进一步提升系统的稳定性与泛化能力。

秦子宸

8/20/2025