

短视频（快手）视频数据基本特征与视频质量模型报告

一、 主要数据类型

本数据集主要来自于“快手短视频”2022 年 4 月~5 月两个月期间的视频数据、用户数据、平台日志等。在本次报告中，主要使用了视频基础特征数据集（“video_feature_basic_pure”），数
维度主要包含视频 id、作者 id、视频类型、上传方式、上传时间、视频持续时间、音乐 id、分
辨率、标签等，数据量超过 7000。此外还使用了视频统计数据集，主要是视频完播率、点赞数
等。

数据预处理主要包括去除空值（NULL），以及修改数据类型等。其中，视频类型为广告的数据在 music_id 和 muic_type 栏皆为空值，可能是因为没有统计或者视频类型为照片造成的，所以在预处理中全部改为了 0，方便后续进行研究和计算。

二、 分析目录

1. 统计型

- 1) 统计不同类型视频（`video\_type`，如 NORMAL 或 AD）的数量和占比。
- 2) 通过 `tag` 字段提取视频的关键类别，并统计每个类别的视频数量。
- 3) 统计不同日期（`upload\_dt`）上传的视频数量，分析上传时间的分布。
- 4) 统计不同可见状态（`visible\_status`）的视频数量，分析可见状态对视频曝光的影响。（无法实现）
- 5) 统计视频时长（`video\_duration`）的分布情况，计算平均时长、中位数时长等统计指标。
- 6) 分析视频的宽度（`server\_width`）和高度（`server\_height`）的分布情况，计算常见分辨率的比例。
- 7) 统计不同背景音乐 ID（`music\_id`）的使用

2. 建模分析型

- 1) 结合视频时长（`video\_duration`）、分辨率（`server\_width` 和 `server\_height`）等指标，评估视频的整体质量。
- 2) 分析视频上传类型（`upload\_type`）对用户体验的影响，例如，不同上传方式的视频质量差异。

三、 统计建模方法和技术要点

本次研究的统计部分主要使用 MySQL 的查询，以及 Matplotlib 库。

在统计视频时长的时候，考虑到不同时长区间里，人们对时长差的敏感度不一样（比如短视频中 30 秒与 40 秒的差距，比长视频里 30 分钟与 35 分钟的差距更突出），所以对比时最好按视频长短分段进行，这样会更合理。所以这里首先定义了时间区间（0~600s 是每 30s 一个区间，600s~3600s 是每 5 分钟一个区间），再进行视频时长区间分布统计，从而更好的展现分布效果。

在统计视频分辨率时，由于部分视频是竖版的，存在分辨率完全一样，但是长和宽对调的情况，盲目进行统计会多输出另外一中分辨率。这里采用的方式是按大小将宽和高进行重新排序，保证较长的边在前，短边在后，从而确保相同像素的分辨率得到相同标识。

针对视频质量等级，主要建了一个打分模型，根据不同的数据维度对该视频的整体质量进行评估。在研究中，关联查询了视频的分辨率、点赞数、完播量、评论数、已播率等数据，并对每种数据维度构建了打分标准，保证每个区间的增长幅度相同，比如点赞数从 0~100 得 1 分，


100~300 得 2 分，300~600 得 3 分，600~1200 得 4 分（每个区间大小的增长幅度为上个区间上限的 100%）。随后通过 `pd.cut` 的方法，将数据进行分段，并且将每段种的数据最后一列（score 列）加上对应的分数。再算完所有分数后，按照一定的等级，将不同的视频质量进行分级。质量最高的视频为 1 级视频，质量最低的视频为 4 级视频。每个等级的分数区间是 0~7 分，7~14 分，14~21 分，21 分以上。再计算完后，再通过查询原始数据，将打分后的数据和原始数据利用 `pd.merge` 的方法整合到一起，从而分析不同上传途径的视频质量。

四、 统计分析结果

1. 不同类型视频的数量和占比

总共有以下 3 种，数量和占比如下：

	video_type	count	percent
0	NORMAL	7506	98.98
1	AD	76	1.00
2	UNKNOWN	1	0.01




根据数据可知，在本数据集中，绝大部分（98.98%）都是常规视频，只有少数的广告和一个未知视频。未知视频可能是因为统计失误或者上传的网络问题，在误差范围内（小于等于 0.05%），所以可以忽视。

2. 每个类别的视频数量（top5）和上传时间的分布

	tag	count
0	39	815
6	3	651
4	9	418
13	6	378
27	20	344
3	7	340


视频标签分布统计(top20)

视频发布时间分布统计



3. 视频时长的分布情况

视频时长区间分布




由图可见，上传的视频中最多的短视频（0~30 秒），其次是 1 分钟左右的中长度视频。该平台大部分视频都是短视频，越长的视频越少。

4. 常见分辨率的比例

	normalized_resolution	count	占比(%)
0	720.0×1280.0	6457	85.15
1	720.0×960.0	269	3.55
2	720.0×1282.0	117	1.54
3	720.0×720.0	59	0.78
4	1080.0×1440.0	48	0.63


视频分辨率分布统计




本数据集绝大部分视频的分辨率都是 720*1280，而有少部分的分辨率在 710*960 以下（不足 10%），说明绝大部分的上传都是长方形高画质的视频。

5. 背景音乐 ID 的使用频率和背景音乐类型的分布

音乐使用频率图



音乐类型分布图



使用最多的音乐类型是 9 类，其次是 4 类。使用的最多的音乐 id 是 9104719068，断档领先于其他的类型。

五、 建模分析结果


1. 打分体系建模效果展示

最右侧是视频等级，质量最高的视频为 1 级视频，质量最低的视频为 4 级视频。每个等级的分数区间是 0~7 分，7~14 分，14~21 分，21 分以上。


video_id	video_duration	like	complete_play	share	commnet_user_number	play_progress	resolution	quality_level	
0	0	874.33	6.470588	195.254902	0.058824	0.196078	0.117407	1280.0x720.0	3
1	1	2180.66	38.161765	130.507353	1.698529	2.345588	0.064726	1280.0x720.0	3
2	2	92.33	6.626374	80.208791	0.197802	1.208791	0.238342	1280.0x720.0	3
3	3	164.33	5.402778	115.930556	0.013889	0.041667	0.217354	1280.0x720.0	3
4	4	387.66	457.235955	1329.078652	24.865169	38.202247	0.308945	1280.0x720.0	2
5	5	3580.16	137.287356	496.954023	0.965517	3.965517	0.100842	720.0x960.0	3
6	6	1145.00	93.811475	678.368852	0.426230	2.090164	0.169716	720.0x960.0	3
7	7	0.00	13.643564	5.693069	0.504950	0.237624	0.031681	1440.0x720.0	4
8	8	1503.66	1711.177778	3406.238889	17.933333	53.577778	0.128284	1280.0x720.0	2
9	9	619.33	18.303030	192.659091	2.045455	0.439394	0.107336	1280.0x720.0	3
10	10	608.16	14.127660	73.957447	0.063830	0.425532	0.115645	1280.0x720.0	3
11	11	1374.80	57.253333	1669.473333	0.360000	0.433333	0.169997	1280.0x720.0	3
12	12	202.00	14.910256	166.102564	0.076923	0.282051	0.152695	1280.0x720.0	3
13	13	1748.39	2.485437	6.582524	0.203883	0.067961	0.026949	1280.0x720.0	3
14	14	253.66	8.516393	60.737705	0.073770	0.385246	0.085634	1280.0x720.0	3
15	15	194.64	26.303030	217.848485	1.689394	3.901515	0.159418	1280.0x720.0	3
16	16	1334.80	41.500000	973.009091	0.363636	1.336364	0.164211	1280.0x720.0	3
17	17	337.00	326.427778	197.600000	2.938889	7.288889	0.135566	1280.0x720.0	3
18	18	1276.07	1.343284	85.716418	0.014925	0.059701	0.141039	1280.0x720.0	3
19	19	183.66	432.765363	10489.284916	1.217877	32.491620	0.355721	1280.0x720.0	2

2. 不同上传类型对用户体验的影响

不同上传方式的视频质量箱线图如下（越低的箱视频质量越高）：



本图可见，通过 LongImport、ShortImport 上传的视频水平整体比较高，但是上下限差距很大。而通过 LongPicture 和 PictureSet 上传的视频质量都不高，评分都比较低，绝大部分都在 3~4 级之间。上传方式中，通过 PhotoCopy、AiCutVideo、LipsSync 上传的视频质量最差，最高等级为 3 级，也只有 3 级。



本图是根据不同种类上传方式的视频等级均值绘制而成，包括标准差。从本土可见广告 (AD) 的视频质量最高，而 LongPicture 和 PictureSet 最低，且浮动很大 (标准差大)。而通过 LongCamera 和 FollowShoot 上传的视频整体不算高，但是整体质量最均很，浮动最小 (标准差小)。

六、 结论和讨论

本研究主要包含多个数据特征分析以及一个打分体系模型，针对来自短视频平台短期内的

数据进行了初步的研究，分析该平台视频的基本数据特征，从而能够加强读者对于本数据和该平台视频的主要认知，为以后的数据研究做好了铺垫。

本研究的主要优点在于主要通过统计的方式进行研究，并且包含大量可视化图像，让研究结果清晰易读。此外，模型的打分区间和视频时间区间都采用分段的方式，能让不同时长维度下的打分标准与用户实际感知更贴合，避免因跨区间对比导致的认知偏差，符合人们对于比例对比和数值对比之间的认知差异，让结构更加合理。

本研究依旧可以改善的地方在于数据量相对较少，所以有些数据不够显著，甚至存在误差较大的情况（比如本数据集种所有的视频都是在于不可见状态，无法进行分析）。在以后的研究中，首先应该增加数据量，并且可以改善分析方法，将本数据集中更多的数据特点和统计量进行展示。

秦子宸

8/6/2025