

视频每小时点赞量混合预测模型分析报告

一、模型核心目标

该模型核心目标为对视频每小时互动峰值和总量开展时间序列预测，一方面，依托历史 2 周小时级点赞数据，完成未来 24 小时每小时点赞量的短期预测，并与真实数据对比验证模型效果，同时在此基础上，额外延伸预测后续 24 小时数据，实现“24 小时验证 + 24 小时延伸”的 48 小时连续预测；另一方面，同步识别预测周期内的点赞量峰值，涵盖 24 小时验证期的预测峰值、真实峰值，以及 24 小时延伸期的预测峰值，为流量调度、内容推荐等业务决策提供参考。

二、使用模型和模型介绍

模型主要遵循“数据获取→数据预处理→时间序列分解→多模型训练→混合预测→结果可视化”的流程，具体步骤如下

1. 时间序列分解

采用季节性分解 (seasonal_decompose) 将每小时点赞量数据拆分为趋势项（长期变化规律）、周期项（24 小时日内波动）和残差项（随机波动）。通过对比残差方差，自动选择加法或乘法分解模型，适配不同数据波动特性。

2. SARIMA 模型

针对分解后的“趋势 + 周期”组合项建模，捕捉时间序列的长期趋势和日内季节性。通过自回归 (AR)、差分 (I)、移动平均 (MA) 及季节性组件，预测未来 48 小时的趋势与周期叠加结果。

3. 随机森林回归

对分解后的残差项建模，利用小时、是否周末、星期几等时间特征，学习随机波动规律，修正 SARIMA 的预测误差。通过 100 棵决策树（最大深度 7）平衡拟合精度与泛化能力。

4. 混合预测策略

结合 SARIMA 的趋势周期预测与随机森林的残差预测，根据分解类型（加法 / 乘法）进行结果融合，确保预测值非负（点赞量不可能为负），最终输出 48 小时连续预测结果。

三、模型构建主要流程

步骤 1：数据获取与分割 (get_data 函数)

1. SQL 查询提取原始数据

关联两张业务表：log_standard（用户行为日志表）：获取 user_id（用户 ID）、video_id（视频 ID）、date（日期）、hourmin（时分）、time_ms（时间戳，毫秒级）；以及 video_features_statistic_pure（视频特征表）：获取 video_id 对应的 like_cnt（点赞量）；通过 video_id 内连接两表，确保每个用户行为日志匹配对应的视频点赞量。

2. 数据预处理

- 类型转换：time_ms 转为数值型，再通过 pd.to_datetime(..., unit='ms') 转为可读时间 (readable_time)，并按小时取整得到 hour（小时级时间索引）；
- 异常值处理：like_cnt 转为数值型，缺失值填充为 0（无点赞记录视为 0 点赞）；
- 小时级聚合：按 hour 分组求和 like_cnt，得到“每小时总点赞量”时间序列，并通过 asfreq('H', fill_value=0) 补全缺失的小时时间点（确保时间序列连续）。

该模型的训练集与测试集分割以输入的 train_cutoff（训练截止时间，默认值为 2022-05-07 00:00:00）为核心基准：其中训练集涵盖 train_cutoff 前 2 周至 train_cutoff 的所有小时级数据，共 $2 \times 7 \times 24 = 336$ 小时，确保能覆盖 2 个完整的日内周期以支撑模型学习周期性规律；测试集则选取

train_cutoff 后 1 小时至 24 小时的小时级数据，共 24 小时，专门用于模型预测效果的验证；同时，流程中设置了数据完整性检查机制，若训练集为空或测试集实际时长不足 24 小时，将直接抛出异常提示，保障后续建模数据的有效性。

步骤 2：混合模型训练与预测（train_hybrid_model 函数）

该步骤是模型核心，分为“时间序列分解→SARIMA 训练→随机森林训练→混合预测”4 个子环节：

时间序列分解（加法 / 乘法自动选择）

1. **数据适配**：为避免乘法分解中 0 值导致的计算错误，对训练集数据加 1 ($\text{train_data_adj} = \text{train_data} + 1$)；
2. **双模型分解**：分别用加法 (additive) 和乘法 (multiplicative) 模型分解数据，得到两组“趋势 + 周期 + 残差”；
3. **最优分解选择**：计算两组分解结果的残差方差，选择残差方差更大的模型（更能反映数据波动，便于后续残差修正）；
4. **结果还原**：将分解后的趋势、周期、残差与原始训练集时间索引对齐，若为乘法模型，需将残差减 1 以还原原始数据尺度。

模型一：SARIMA 模型训练（趋势 + 周期预测）

1. **模型参数设置**：
 - 基础参数 ($\text{order}=(1,1,1)$)：AR (1) 自回归项、I (1) 差分（确保序列平稳）、MA (1) 移动平均项；
 - 季节性参数 ($\text{seasonal_order}=(2,1,1,24)$)：季节性 AR (2)、季节性差分 I (1)、季节性 MA (1)、周期长度 24（日内季节性）；
2. **模型训练**：基于分解后的“趋势 + 周期”组合项训练 SARIMA 模型，禁用平稳性 / 可逆性强制约束（适配实际数据特性）；
3. **趋势 + 周期预测**：用训练好的 SARIMA 模型预测未来 48 小时（24 小时测试 + 24 小时延伸）的“趋势 + 周期”值。

模型二：随机森林训练（残差预测）

1. **特征工程**：构建残差预测的特征集，包含 3 类时间特征：
 - hour：小时（0-23，捕捉日内波动）；
 - is_weekend：是否周末（0 = 工作日，1 = 周末，捕捉周度波动）；
 - day_of_week：星期几（0-6，捕捉周内差异）；
2. **模型训练**：用残差作为目标变量，时间特征作为输入，训练随机森林回归模型（100 棵树，最大深度 7，确保模型拟合且不过拟合）；
3. **残差预测**：基于未来 48 小时的时间特征，用训练好的随机森林预测对应残差。

混合预测（结果组合）

根据之前选择的分解模型（加法 / 乘法），组合 SARIMA 的“趋势 + 周期”预测值与随机森林的残差预测值：

- 加法模型：混合预测值 = SARIMA 预测值 + 残差预测值；
- 乘法模型：混合预测值 = SARIMA 预测值 $\times$ (1 + 残差预测值)；
- 边界处理：用 $\text{clip}(\text{min}=0)$ 确保预测值非负（点赞量不可能为负）。

最终将预测结果拆分为“24 小时测试期预测”和“24 小时延伸期预测”，并识别两个周期内的点赞峰值（时间 + 数值）。

效果展示：

选择加法模型进行时间序列分解

trend 非零样本数： 337

seasonal 非零样本数： 337

residual 非零样本数： 337

residual 样本预览： [12297.438645514834, -52085.34075057176, 117245.51252644986, 279504.83115407574, -64938.41111715231, 259098.28554015368, 273298.46117136965, 132073.995833086, 359028.9938574579, 155858.57884031715]

=== 对比部分 ===

预测峰值：2022-05-07 13:00，点赞量：1333030

真实峰值：2022-05-07 11:00，点赞量：1076635


=== 延伸预测部分 ===

延伸预测峰值：2022-05-08 13:00，点赞量：1326216

步骤 3：结果可视化与输出 (plot_results 函数 + 主程序)

1. **可视化输出**：模型生成包含 2 个子图的综合图表。子图 1（时间序列分解）：展示训练集最后 7 天的原始数据、“趋势 + 周期”、残差，验证分解效果；子图 2（预测对比）：展示训练集最后 7 天数据、测试期真实值、测试期预测值、延伸期预测值，并标记各周期峰值和关键时间节点（训练截止点、延伸预测起点）；
2. **文本输出**：打印关键结果（测试期预测峰值 vs 真实峰值、延伸期预测峰值），便于量化评估模型效果。

效果展示：



该可视化结果包含时间序列分解与混合模型预测对比两部分。上图基于加法模型对最后 7 天数据分解，灰色原始数据呈现每小时点赞量日内波动，蓝色趋势 + 周期线提取常规变化模式，黄色残差体现随机波动；下图展示模型预测表现，浅蓝色为训练最后 7 天数据，24 小时验证期（2022-05-07）内，混合模型预测峰值数值为 1333030，真实峰值数值为 1076635，预测值高于真实值，误差绝对值约 256395，约为真实值的 24%。但红色预测曲线与绿色真实值曲线整体趋势高度贴合，可捕捉日内多峰波动；延伸预测期（2022-05-08 及之后），紫色延伸预测峰值数值为 1326214，呈现后续 24 小时走势，两个预测值之间有显著的不同，说明第二次的预测有根据之前的修复倾向，并且也更符合长期的数据走向和整体趋势。

四、总结

该模型的核心优势体现在多维度技术特性的协同优化：其一，采用混合建模架构，有机融合 SARIMA 模型对时间序列“趋势-周期”耦合特征的强刻画能力，与随机森林对残差序列“非线性波动”的高效拟合能力，有效突破单一模型（纯 SARIMA 或纯机器学习模型）在复杂时序规律捕捉上的局限性，显著提升预测精度；其二，具备数据自适应能力，通过残差方差量化对比机制，自动遴选加法或乘法分解模型，无需人工参数干预即可动态适配不同场景下的数据波动特性；其三，在长期预测任务中，模型可规避单一趋势的固化输出问题，依托时序规律的动态学习机制实现自我调节，确保在时间维度上持续维持较高的预测准确度。